A-Net 实验总结

结果、优势与代价

截至 2026-10-30 · 分支 experiment/anet-v2 · 记录时提交 45ec348

实验环境：RTX 5060 Laptop（8 GB 专用显存） · 15.18 GB RAM · PyTorch 2.14.1+cu130

执行摘要

本报告汇总 A-Net v2 在 2D 合成任务、缓存基准、50M char-level 语言 pilot，以及激活参数/共享深度对照中的全部主要结果。结论分为“机制成立”“能力证据”“成本权衡”“尚未验证”四类，避免把 pilot 结果写成大模型结论。

- 参数所有权、引用、版本、缓存失效和隔离机制均已实现并通过测试；最新测试 75 passed。
- 参数共享能显著降低唯一参数：Stage 1 A-Net Full 0.651×；Stage 2 Share 0.656×；Stage 4 W=3 0.67×、W=4 0.63×。
- 在 50M pilot 中，Sparse A-Net 因有效深度仅 6 层而明显更差（2.141 bpc）；修正为 12 层 Shared-Depth A-Net 后，以 1.933 bpc 略优于 Transformer-12L 的 1.991 bpc（p≈0.046）。
- 该 50M 结果只是 pilot：3 seeds、3M tokens、char-level 三域数据；不是 MMLU/GSM8K/HumanEval 能力结论。
- 推理延迟只有条件性优势；显存和训练时间没有普遍优势。Sparse A-Net 训练峰值更低（1.69 vs 1.98 GB），但以深度/能力为代价。
- 2B 全参数训练在本机不可行（约 32 GB 训练状态 vs 8 GB GPU / 15 GB RAM）；1B 最终验证需要外部 8×H100 级资源。

1. 实验口径与边界

所有架构使用相同的唯一参数、激活参数、引用参数和存储统计口径。共享参数只在唯一参数量中计一次；参数引用总量允许重复；单次前向激活唯一参数按实际调用路径统计；存储按 FP32 唯一参数估算。

口径	定义
唯一可训练参数	去重后的 requires_grad 参数总量；共享参数只计一次
参数引用总量	按调用点累计，共享块被多个 workflow 调用会重复计入
单次前向激活唯一参数	一次 forward 中实际执行的唯一参数
参数共享比例	共享参数元素 / 唯一参数，或按具体对照说明
实际存储	唯一参数 × 4 bytes（FP32）

数据来源：Stage 1–4 为 2D 合成任务；50M pilot 为 byte-level Tiny Shakespeare + CPython 源码 + 合成数学；2B 仅做可行性审计，没有训练。

证据强度：Stage 1–4 使用 3–5 seeds；50M pilot 使用 3 seeds；p 值仅作 pilot 级参考。没有正式的多重比较校正或大模型复现。

2. 实验矩阵

实验	规模	状态	主要用途
Stage 1	360 runs	完成	宽度 scaling；精度/参数/延迟/吞吐
Stage 2 耦合	315 runs	完成	共享的负迁移/梯度冲突
Stage 2 隔离	315 runs	完成	detach_both 隔离对照
Stage 3	288 cache streams	完成	缓存正确性、命中、延迟、内存
Stage 4	540 runs	完成	share × cache × 宽度 × workflow 数
50M 语言 pilot	9 runs	完成	Transformer/Shared/Sparse A-Net
激活匹配对照	3 runs	完成	Transformer-12L vs Sparse A-Net
对照 C 共享深度	3 runs	完成	12 层 Shared-Depth A-Net vs Transformer-12L
2B	未执行	不可行	本机资源不足；只做可行性审计

3. Stage 1：基础架构 scaling

360 个 run，0 失败；3 seeds；h64/h256/h1024/h2048；3 个合成 2D 任务。下表为相对 Independent 的平均值。

模型	平均精度	唯一参数比	激活参数比	batch1 P50	大 batch 吞吐
A-Net Basic	−0.067 pp	0.967×	0.996×	2.65×	0.61×
A-Net Full	−0.216 pp	0.651×	0.996×	4.75×	0.47×
Shared Backbone	−1.367 pp	0.341×	1.000×	相近	相近

解释：A-Net 精度接近 Independent，但不是计算/延迟胜利；Shared Backbone 存储最少但精度损失最大。A-Net 位于“比 Independent 省存储、比 Shared 保精度”的中间位置。
重构后 A-Net Full 的 batch1 P50 从约 555 us 降到约 198 us（纯路径），但仍约为 Independent 的 2.3–2.6 倍。

4. Stage 2：共享的收益与隔离

耦合共享（315 runs）中，A-Net Share 相对 Independent 唯一参数 0.656×、激活参数 1.48×，但平均精度 −1.20 pp；Basic −0.95 pp、Adapter −1.63 pp。梯度 cosine 约 +0.025、冲突比例约 0.43；task0 负迁移 −2.14 pp，回归 MSE +0.0106。
隔离版（detach_both，315 runs）显著改善负迁移：

模式	相对耦合版提升	说明
pair Basic	+0.856 pp	隔离辅助 workflow
pair Share	+1.126 pp	共享块冻结，避免冲突
pair Adapter	+1.493 pp	adapter 也不接收冲突梯度
dense Basic	+1.599 pp	更明显的隔离收益
dense Share	+1.681 pp	dense 路由
dense Adapter	+1.750 pp	dense 路由

隔离版绝对精度：Independent 95.87%、Basic 95.77%、Share 95.80%、Adapter 95.73%；pair Share 相对 Independent 仅 −0.07 pp。task0 低 0.22–0.29 pp，回归 MSE +0.0020–0.0022。
代价：detach_both 同时冻结共享块输出和辅助 workflow，共享块不再接收梯度；如果要求共享块继续学习，应改用 detach_aux 或梯度手术。

5. Stage 3：结果缓存

288 个 cache stream，0 失败。cache on/off 输出最大绝对差 0.0；参数更新后 100% 失效；H2D = 0；所有输入在 cuda:0。

指标/场景	结果
命中率（Reuse）	精确等于输入重复率：0/25/50/75%
命中率（Full）	额外 20%：pair 内共享块复用
执行次数（75% 重复）	Reuse 25%，Full 20%
batch=1 延迟	cache 更慢 1.14–1.85×
2048 宽 / batch256 / 75%	Reuse 0.68×，Full 0.67×
2048 宽 / batch256 / 50%	Full 0.98×，接近盈亏平衡
缓存内存	最高 256 MB；最多 786 次 eviction
查找成本	约 1.33 us/次

结论：缓存不是普遍加速；只有大宽度、大 batch、高重复率才有净收益。默认 inference cache 关闭。

6. Stage 4：共享 × 复用 × 宽度 × workflow 数

540 个训练 run，0 失败；3 seeds；2×2 因子（share × cache）；W=2/3/4；宽度 128/512/2048。

配置	唯一参数比（相对 Basic）	精度效应
A-Net Share，W=2	0.76×	W=2 容量不足，+0.3–1.1 pp
A-Net Share，W=3	0.67×	约中性（−0.16–+0.15 pp）
A-Net Share，W=4	0.63×	约中性（−0.10–+0.13 pp）

Reuse 的精度效应严格为 0：训练每个 optimizer step 清空缓存，缓存只影响推理。交互项为 0：共享与复用没有额外精度协同。

Workflow 数：W=2 明显容量不足（平均 83.92% vs W=3 95.77%、W=4 95.87%）；W=4 相对 W=3 没有稳定精度收益，但唯一参数继续增加。

缓存对照（width=2048、W=3、medium）：batch=1 全部更慢；batch=256、75% 重复时 Reuse 0.68×、Full 0.67×；50% 重复时 Full 0.98×。

7. 50M 语言 pilot

这是本机可执行的最小语言代理实验，不是 MMLU/GSM8K/HumanEval 能力结论。数据为 Tiny Shakespeare、CPython 源码、合成数学；byte-level vocab=256；3 seeds；每 seed 1500 步、batch 16、seq 128，约 3M tokens；AdamW、FP32。

模型	唯一参数	单次激活参数	有效深度	平均 bpc
A-Net Shared-Depth	50.18M	37.50M	12	1.933 ± 0.067
Transformer-12L	37.50M	37.50M	12	1.991 ± 0.033
Shared Backbone	50.18M	50.18M	16	1.975 ± 0.028
Transformer-16L	49.92M	49.92M	16	2.007 ± 0.055
Sparse A-Net	50.18M	37.50M	6	2.141 ± 0.107

三架构原始对照：Transformer 2.007、Shared Backbone 1.975、Sparse A-Net 2.141。Sparse A-Net 更差的主要原因是有效深度只有 6 层，而不是“共享一定伤害能力”。

激活匹配对照：Transformer-12L（37.503M 激活）1.991 vs Sparse A-Net（37.502M 激活）2.141；差 +0.150 bpc，Welch p≈0.019。该对照排除了“只是激活参数少”，但仍存在深度/路由混淆。

8. 对照 C：Shared-Depth A-Net

为消除深度混淆，构造 8 个共享 block + 2 个 workflow 各 4 个专属 block 的 12 层路径：
embedding → 8 shared blocks → 4 task-workflow blocks → task head

项目	A-Net Shared-Depth	Transformer-12L
唯一参数	50,177,024	37,503,168
单次激活参数	37,501,632	37,503,168
激活参数差	1,536（0.0041%）	—
顺序深度	12	12
共享比例	49.5%	0%
参数引用总量	75,002,496	37,503,168
FP32 唯一存储	200.7 MB	150.0 MB

模型	text	code	math	平均
A-Net Shared-Depth	2.537	1.736	1.527	1.933 ± 0.067
Transformer-12L	2.635	1.815	1.523	1.991 ± 0.033
差值（A-Net − 对照）	-0.098	-0.079	+0.004	-0.058

Welch t≈-3.35，p≈0.046；A-Net 在 text/code 更好，math
基本打平。该结果支持“共享深度可以在不牺牲深度/激活计算的情况下保持能力”，但只有 3 seeds、3M tokens，属于 pilot 级证据。

9. 成本：推理、显存、训练时间

指标	A-Net Shared-Depth	Transformer-12L	结论
batch1 P50	3.00 ms	4.70 ms	A-Net 0.64×，更快
batch16 P50	14.89 ms	15.23 ms	基本持平
训练峰值显存	1.59 GB	1.51 GB	A-Net 更高
唯一参数存储	200.7 MB	150.0 MB	A-Net 更高
训练时间/seed	100.3 s	101.7 s	约 1%，无实质差异

模型	唯一参数	单次激活	训练峰值	训练时间
Sparse A-Net	50.18M	37.50M	1.69 GB	94.6 s
Transformer-16L	49.92M	49.92M	1.98 GB	121.7 s
Shared Backbone	50.18M	50.18M	2.11 GB	120.8 s
Shared-Depth A-Net	50.18M	37.50M	1.59 GB	100.3 s
Transformer-12L	37.50M	37.50M	1.51 GB	101.7 s

Sparse A-Net 的训练峰值和训练时间确实更低（1.69 GB / 94.6 s），但这是以只激活 2/3 workflow、有效深度 6 层、能力更差为代价。Shared-Depth A-Net
保住了深度/能力，但唯一参数更多，训练显存反而略高。Stage 1 中 A-Net
推理更慢、训练更慢；缓存只在特定场景回本。

10. 优势

- 参数所有权、唯一存储、版本、授权调用和缓存失效机制正确，可审计；不是隐式全局共享。
- 参数共享降低唯一参数：Stage 1 Full 0.651×；Stage 2 Share 0.656×；Stage 4 W=3 0.67×、W=4 0.63×。
- 在 50M 同深度/同激活参数对照中，Shared-Depth A-Net 1.933 bpc 略优于 Transformer-12L 1.991 bpc（p≈0.046，pilot）。
- 隔离（detach_both）显著改善多任务负迁移：pair Share 相对耦合 +1.13 pp，dense +1.68 pp；隔离版接近 Independent。
- 结果缓存正确；高重复、大 batch、大宽度下执行次数和延迟下降（最高约 0.67×）。
- Sparse A-Net 训练显存/时间更低（1.69 GB/94.6 s），适合激活路径受限的场景，但能力下降。
- 工程上 GPU-resident、H2D=0、显存守卫、五口径核算和 75 个测试，便于复现和审计。

11. 劣势与代价

- A-Net 不是普遍的计算/延迟胜利：Stage 1 Basic/Full batch1 为 2.65×/4.75×，吞吐 0.61×/0.47×，训练时间 1.21×/1.33×。
- Sparse A-Net 把有效路径从 12 层降到 6 层，唯一参数 50M 但单次只激活 37.5M；能力明显更差（2.141 bpc）。
- Shared-Depth A-Net 的唯一参数反而比 Transformer-12L 多 12.7M，训练显存 1.59 vs 1.51 GB 更高；共享不是“更省显存”的同义词。
- 训练时间没有普遍优势；Shared-Depth 100.3 vs 101.7 s，约 1% 差异。
- 缓存有明显开销：batch=1 慢 1.14–1.85×，最高 256 MB，查找 1.33 us/次；只有高重复/大 batch 回本。
- detach_both 冻结共享块，牺牲共享表示学习；要共享块继续学习必须换 detach_aux/梯度手术。
- Workflow 数存在容量阈值：W=2 对 3 任务容量不足；W=4 无稳定精度收益但参数更多。
- 工程复杂度高：registry、版本、DAG、cache、隔离、设备守卫；比普通 Transformer 更难维护。
- 50M pilot 只有 3 seeds、3M tokens、char-level 数据；p≈0.046 接近 0.05，不能当作最终显著性。
- 没有 MMLU/GSM8K/HumanEval、SFT、1B/2B 实验；2B 本机不可行。

12. 统计与证据强度

结果	样本	统计	证据强度
Shared-Depth 优于 Transformer-12L	3 seeds	均值差 -0.058 bpc；p≈0.046	pilot 级；接近阈值
Sparse 差于 Transformer-12L	3 seeds	均值差 +0.150 bpc；p≈0.019	pilot 级；有深度混淆
Stage 1/2/4	3–5 seeds	均值/标准差；无正式校正	趋势级
Stage 3 cache	288 streams	输出等价、命中/延迟	机制级，较强
2B	0	未执行	无能力证据

13. 结论

支持的结论：

- A-Net v2 的参数共享、所有权、版本、缓存、隔离机制可以正确实现。
- 共享能降低唯一参数；在 W=3/4 下 Stage 4 唯一参数比约 0.67×/0.63×。
- 在 50M pilot 的同深度/同激活参数对照中，Shared-Depth A-Net 略优于 Transformer-12L（p≈0.046）。
- 隔离改善负迁移；缓存正确且在高重复/大 batch 下有条件收益。

不支持的结论：

- A-Net 无条件优于 Transformer。
- A-Net 计算更少、延迟更低或显存更省。

- 1B/2B 语言能力已超过 Transformer。
- 结果复用显著提升训练能力。
- Sparse A-Net 的失败证明共享机制无效。

总体判断：A-Net

当前最可靠的定位是“以参数共享换唯一存储、以隔离换稳定、以缓存换特定场景执行”的架构；能力优势仅在 50M pilot 的 Shared-Depth 对照中初步出现，仍需更大规模复现。

14. 下一步

- 补 5–10 seeds 和更长 token 预算，复现 Shared-Depth 的 0.058 bpc 差异。
- 做 dense A-Net、shared-depth、不同共享位置/深度的消融，确认增益来自共享而非实现细节。
- 在 1B 规模、20B–100B tokens、标准评测上验证；需要 8×H100 级资源。
- 补 cache 的端到端推理基准和显存/吞吐测量；当前只证明条件性收益。
- 把“训练显存低”限定为 Sparse A-Net 的代价性优势，不推广到 Shared-Depth。

附录：产物与提交

文件/产物	说明
README.md	项目总览与最新结论
experiments/anet_v2/STAGE1_REPORT.md	Stage 1 报告
experiments/anet_v2/STAGE2_REPORT.md	Stage 2 耦合报告
experiments/anet_v2/STAGE2_ISOLATED_REPORT.md	Stage 2 隔离报告
experiments/anet_v2/STAGE3_REPORT.md	缓存报告
experiments/anet_v2/STAGE4_REPORT.md	Stage 4 因子报告
experiments/anet_v2/lang50m/REPORT.md	50M 三架构报告
experiments/anet_v2/lang50m/ACTIVE_MATCH_REPORT.md	激活匹配对照
experiments/anet_v2/lang50m/SHARED_DEPTH_REPORT.md	对照 C 共享深度
experiments/anet_v2/scale2b/FEASIBILITY.md	2B 可行性

分支：experiment/anet-v2；记录时提交：45ec348；测试：75 passed。所有原始结果和报告已推送到 GitHub 分支。

说明：本报告由实验数据自动汇总生成；没有使用小模型冒充 1B/2B，也没有把随机权重或 pilot 结果写成语言能力结论。